

Análisis de Perfiles de Inversión mediante Clustering y Reducción de Dimensionalidad

Avance de Proyecto - Machine Learning

Ricardo Delgadillo Diaz

Universidad El Bosque

Facultad de ciencias

Matemáticas y ciencia de datos

Bogotá, D.C.

2026

Repositorio Oficial del Proyecto (GitHub)

<https://github.com/RicardoDiaz/clustering-perfiles-inversion>

Introducción

La gestión financiera es un método muy usado per la clasificación de activos por sectores comunes como tecnología, energía o salud suelen falla al capturar el comportamiento real del mercado durante periodos de estrés o alta volatilidad. Mediante este proyecto surge de la necesidad de lograr agrupaciones basadas en la covarianza y correlación real de los datos históricos.

El problema central consiste en encontrar estructuras ocultas o no visibles a simple vista de riesgo y rendimiento sin depender de etiquetas predefinidas. Se busca centrarse en procesar series de tiempo de activos para validar si el aprendizaje no supervisado puede segmentar de manera efectiva regímenes de mercado distintos.

Objetivos del Avance

Implementar la extracción, limpieza y preprocesamiento de datos financieros.

Aplicar reducción de dimensionalidad (PCA) y clustering (K-means) para observar la formación de grupos iniciales.

Justificar la selección de parámetros óptimos (k) mediante criterios técnicos como el Método del Codo.

Datos

Fuente: Yahoo Finance a través de la librería yfinance.

Se descargaron registros desde enero de 2023 hasta abril de 2026 para 7 activos clave (AAPL, MSFT, GOOGL, XOM, CVX, GC=F, ^GSPC).

Precios de cierre ajustados, transformados posteriormente a retornos logarítmicos para estabilizar la varianza.

Primeras filas del dataset:						
Ticker	AAPL	CVX	GC=F	GOOGL	MSFT	\
Date						
2023-01-03	123.096031	151.901291	1839.699951	88.389473	233.452805	
2023-01-04	124.365662	150.286179	1852.800049	87.357994	223.240814	
2023-01-05	123.046806	152.992615	1834.800049	85.493401	216.624451	
2023-01-06	127.574211	154.145004	1864.199951	86.624046	219.177460	
2023-01-09	128.095886	152.940201	1872.699951	87.298477	221.311462	
Ticker	XOM	^GSPC				
Date						
2023-01-03	95.434204	3824.139893				
2023-01-04	95.711960	3852.969971				
2023-01-05	97.853439	3808.100098				
2023-01-06	99.036163	3895.080078				
2023-01-09	97.190376	3892.090088				

Figura 1: Muestra del Dataset Procesado

Metodología

Para garantizar que todos los activos financieros tengan el mismo peso relativo en el modelo, se aplicó una transformación de los precios a retornos logarítmicos, seguida de un escalamiento estándar utilizando StandardScaler. Es necesario para que activos con precios nominales altos no dominen el análisis sobre activos de menor precio.

Se implementó PCA para reducir la complejidad del dataset de 7 dimensiones a solo 2 componentes principales.

Los dos primeros componentes logran explicar aproximadamente el 65% de la varianza total de los retornos.

Esta técnica elimina el ruido inherente a las correlaciones financieras y permite una visualización clara de la estructura de los datos.




Figura 2: Visualización Preliminar: PCA

Optimización y Clustering (K-means)

Antes de segmentar los perfiles, se utilizó el Método del Codo para encontrar el balance ideal entre complejidad y precisión.

Se determinó que $k=4$ es el número óptimo de clusters, ya que a partir de este punto la reducción de la inercia no es tan significativa.




Figura 3: Método del Codo

Análisis de Resultados Preliminares




Figura 4: Segmentación de Perfiles de Inversión

En la visualización se observa una concentración significativa de datos en el origen, lo que corresponde a periodos de mercado estables.

El cluster morado agrupa los días de menor riesgo relativo, caracterizados por retornos estables y cercanos a la media.

Los grupos verde y amarillo representan periodos de volatilidad moderada con sesgos direccionales específicos.

Mientras que el grupo azul claro captura los momentos de mayor inestabilidad y riesgo relativo en el dataset.

Tabla de integración

Tema del Curso	¿Se integra?	Cómo se integra en el Proyecto	Por qué aporta al Proyecto
Optimización	Sí	Se aplicó el criterio de minimización de la inercia intracluster mediante el Método del Codo.	Permite encontrar de forma matemática el número de perfiles de inversión (k=4) más eficiente sin segmentar en exceso.
Complejidad del Modelo	Sí	Se utilizó PCA para reducir la dimensionalidad de los retornos financieros antes del clustering.	Evita el sobreajuste al eliminar el ruido de los datos y facilita la interpretación visual de los clusters.
Riesgo Empírico	Sí	Al evaluar la estabilidad de los clusters y la dispersión de los puntos alejados del centroide.	Ayuda a entender qué tan "confiable" es la segmentación frente a datos históricos reales de alta volatilidad.
Kernels / Transformación	Sí	Se realizó una transformación de los datos originales (precios) a retornos logarítmicos/porcentuales y luego a componentes principales.	Esencial para que el algoritmo de ML pueda detectar relaciones no lineales y variaciones relativas entre activos de distinta escala.

Tabla de limitación y riesgos

Limitación Identificada	Impacto en el Modelo	Mitigación Propuesta
Sensibilidad a Outliers	Los eventos de crisis extrema desplazan los centroides, afectando la estabilidad de los clusters.	Implementar técnicas de detección de anomalías o escalamiento robusto en la fase final.
Traslape de Datos	En zonas de baja volatilidad, los límites entre clusters no son estrictamente claros.	Evaluar el uso de Modelos de Mezcla Gaussiana (GMM) para un clustering probabilístico.
Dependencia del Periodo	Los resultados están sujetos a la ventana de tiempo seleccionada (2023-2026).	Realizar pruebas de robustez con ventanas temporales móviles (rolling windows).

Plan de Trabajo Final

Se comparará el desempeño de K-means frente a Clustering Jerárquico y GMM para determinar cuál captura mejor la naturaleza estocástica de los activos.

Se aplicarán métricas de validación interna como el Silhouette Score y el Índice de Davies-Bouldin para confirmar matemáticamente que $k=4$ es la estructura más eficiente.

El objetivo final será cruzar los clusters identificados con una estrategia de Optimización de Portafolio, validando si la segmentación por perfiles de riesgo permite reducir el pérdida acumulada máximo del inversor.